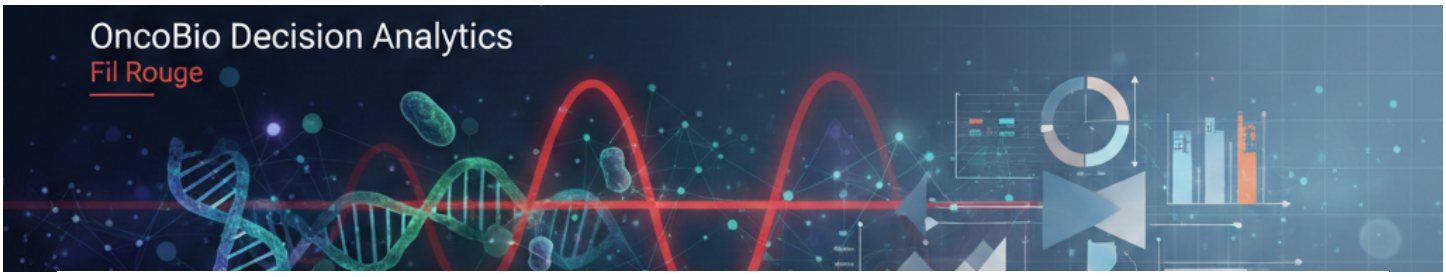


# 🧬 OncoBio Decision Analytics

**Projet Fil Rouge – Formation Data Analyst Simplon**

**Analyse décisionnelle des biomarqueurs associés au cancer à partir de données cliniques et biologiques**

**Réalisé par** **Encadrant**

**Leila Mourid**

**Yassine Ammami**

## Objectif du projet

Ce projet vise à concevoir une **chaîne de traitement de données complète** permettant d'analyser des données cliniques et biologiques liées au cancer afin de produire des **indicateurs décisionnels** utiles aux professionnels de santé et aux équipes de recherche.

L'objectif principal est de **transformer des données hétérogènes** (patients, biomarqueurs, survie) en **informations exploitables** via :

- des analyses statistiques
- une structuration relationnelle
- un tableau de bord interactif

### Périmètre du projet

Le projet couvre l'ensemble du **cycle de vie de la donnée** :

- Extraction multi-sources
- Nettoyage et préparation
- Modélisation en base de données
- Analyse statistique

- Visualisation décisionnelle

## ❓ Problématique

> **Comment exploiter efficacement des données cliniques et biologiques afin d'identifier les biomarqueurs associés au pronostic des patients et d'aider à la prise de décision médicale ?**

## Architecture du projet

Le repository suit une organisation inspirée des **bonnes pratiques Data Engineering** afin d'assurer :

- Reproductibilité
- Traçabilité
- Industrialisation du pipeline

### 📁 Structure des dossiers

```
oncobio_decision_analytics/
├── Data/
│   ├── External_api/
│   │   └── biomarker_reference.csv
│   ├── Interim/
│   │   └── SEER Breast Cancer Dataset.csv
│   ├── Processed/
│   ├── Raw_data/
│   │   ├── biomarkers_data.csv
│   │   ├── patients_clinical_data.csv
│   │   └── treatment_outcomes.csv
│
├── src/
│   ├── Ingestion/
│   ├── Preprocessing/
│   ├── Kpi/
│   └── Script_d'extraction.ipynb
│
├── Notebooks/
├── PostgreSQL/
├── Dashboard_bi/
├── Docs/
│   ├── SEER Breast Cancer Dataset.docs
│   └── cahier_charges_filrouge.docs
│
├── Final_ppt/
├── .gitignore
├── requirements.txt
└── README.md

```

## Sources de données utilisées (Phase actuelle)

### Données cliniques (CSV)

#### Données de survie — Cancer de sein

Les premières analyses reposent sur un **dataset public de cancer du sein** contenant :

- informations démographiques
- caractéristiques tumorales
- données de survie

**Source :** dépôt public Zenodo
👉 Ces données constituent la **base patient** du projet.

#### Données de survie — Cancer du poumon (NCCTG)

Afin de renforcer la dimension pronostique du projet, un second dataset clinique a été intégré.

Il s'agit d'un **dataset clinique réel** contenant des données de survie de patients atteints de cancer du poumon.
Ce dataset est largement utilisé pour les **analyses de survie** et la validation de modèles pronostiques.

#### Variables principales

- **TIME** : durée d'observation / survie
- **Y** :
  - 0 = censuré (vivant)
  - 1 = décès
- **Age** : âge du patient
- **sex** : sexe du patient

Le dataset contient **≈ 228 patients** avec survie réelle.

### Enrichissement biomarqueurs (API NCBI)

Afin d'ajouter une **dimension biologique** au projet, une extraction automatique est réalisée via l'API publique **NCBI Entrez**.

#### Pour chaque biomarqueur (ex : TP53, BRCA1, EGFR), le pipeline récupère :

- identifiant du gène
- nom officiel
- description biologique

📍 **Fichier de sortie :**

```
Data/External_api/biomarker_reference.csv
```

## Pipeline Data

```
Sources → Ingestion → Raw → Cleaning → Processed → PostgreSQL → KPI → Dashboard
```

### 🔹 Étapes du pipeline

#### 1. Ingestion

- CSV (breast + lung)
- API NCBI

#### 2. Préprocessing

- nettoyage des données
- gestion des valeurs manquantes
- harmonisation des colonnes
- création de `patients_master`

#### 3. Feature Engineering

- création de `risk_group`
- normalisation des variables

#### 4. Export SQL

- génération des tables :
  - dim_patients
  - fact_clinical_outcomes
  - dim_biomarkers
  - fact_patient_biomarkers
  - fact_kpis

## Modélisation des données (PostgreSQL)

### Modélisation des données — Schéma en étoile

### Vue globale

Le modèle de données repose sur une architecture en **schéma en étoile (Star Schema)** permettant :

- une analyse performante
- une structuration claire
- une exploitation BI optimisée

### Tables de dimensions

| Table | Champ | Description | Type |
|---|---|---|---|
| **dim_patients** | patient_id | Identifiant unique du patient | Clé primaire |
| | age | Âge du patient | Numérique |
| | sex | Sexe (H/F) | Catégorielle |
| | cancer_type | Type de cancer (Breast / Lung) | Catégorielle |
| | risk_group | Niveau de risque (High / Medium / Low) | Catégorielle |

| Table | Champ | Description | Type |
|---|---|---|---|
| **dim_biomarkers** | biomarker_id | Identifiant unique du biomarqueur | Clé primaire |
| | gene_symbol | Symbole du gène (TP53, BRCA1...) | Texte |
| | gene_id | Identifiant génétique | Texte |
| | description | Description biologique du biomarqueur | Texte |

### Tables de faits

| Table | Champ | Description | Type |
|---|---|---|---|
| **fact_clinical_outcomes** | survival_months | Durée de survie du patient | Numérique |

| | | | |
|---|---|---|---|
| | event | Statut (0 = vivant, 1 = décès) | Binaire |
| | stage | Stade tumoral | Catégorielle |
| | ecog | Score ECOG (état général) | Numérique |
| | patient_id | Référence au patient | Clé étrangère |

| Table | Champ | Description | Type |
|---|---|---|---|
| **fact_patient_biomarkers** | patient_id | Identifiant du patient | Clé étrangère |
| | biomarker_id | Identifiant du biomarqueur | Clé étrangère |

**Relations entre les tables**

| Relation | Description |
|---|---|
| dim_patients → fact_clinical_outcomes | Un patient peut avoir plusieurs observations cliniques |
| dim_patients → fact_patient_biomarkers | Un patient peut être associé à plusieurs biomarqueurs |
| dim_biomarkers → fact_patient_biomarkers | Un biomarqueur peut être associé à plusieurs patients |

## KPI définis

- **KPI cliniques**

| KPI | Description | Objectif métier | Source |
|---|---|---|---|
| Nombre total de patients | Nombre total d'individus dans la cohorte | Évaluer la taille de la population étudiée | dim_patients |

| | | | |
|---|---|---|---|
| Âge moyen | Moyenne de l'âge des patients | Comprendre la distribution démographique | dim_patients |
| Répartition par sexe | Distribution des patients (H/F) | Identifier d'éventuelles différences biologiques | dim_patients |
| Répartition par type de cancer | Nombre de patients par cancer (sein vs poumon) | Comparer les populations étudiées | dim_patients |
| Répartition par groupe de risque | Distribution des patients selon leur niveau de risque | Identifier les segments critiques | dim_patients |

🔹 **KPI pronostiques**

| KPI | Description | Objectif métier | Source |
|---|---|---|---|
| Taux de mortalité (%) | Pourcentage de patients décédés | Évaluer la gravité globale de la cohorte | fact_clinical_outcomes |
| Survie moyenne | Durée moyenne de survie | Mesurer le pronostic global | fact_clinical_outcomes |
| Survie médiane | Durée médiane de survie | Indicateur robuste face aux valeurs extrêmes | fact_clinical_outcomes |
| Survie par stade tumoral | Survie moyenne selon le stade | Analyser l'impact de la progression du cancer | fact_clinical_outcomes |
| Survie par score ECOG | Survie selon l'état général du patient | Évaluer l'impact de la condition clinique | fact_clinical_outcomes |
| Survie par sexe | Comparaison de survie entre hommes et femmes | Identifier des différences biologiques potentielles | dim_patients + fact_clinical_outcomes |

| | | | |
|---|---|---|---|
| Survie par groupe de risque | Survie selon le niveau de risque | Valider la pertinence du scoring de risque | dim_patients + fact_clinical_outcomes |

🔹 **KPI décisionnels**

| KPI | Description | Objectif métier | Source |
|---|---|---|---|
| Répartition des groupes à risque | Distribution des patients en High / Medium / Low risk | Identifier les populations critiques | dim_patients |
| High Risk Burden (%) | Pourcentage de patients à haut risque | Prioriser les interventions médicales | dim_patients |
| Profils patients à haut risque | Segmentation des patients à risque (âge, sexe, cancer) | Définir des stratégies ciblées | dim_patients + fact_clinical_outcomes |
| Biomarqueurs étudiés | Nombre total de biomarqueurs intégrés | Évaluer la richesse biologique du modèle | dim_biomarkers |
| Biomarqueurs les plus représentés | Biomarkers associés à un grand nombre de patients | Identifier les cibles biologiques importantes | fact_patient_biomarkers |
| Couverture biomarqueurs (%) | % de patients associés à au moins un biomarqueur | Évaluer la pertinence biologique du dataset | fact_patient_biomarkers |
| Association biomarqueur-patient | Nombre de liens entre patients et biomarqueurs | Mesurer l'intégration des données biologiques | fact_patient_biomarkers |
| Profils à faible survie | Identification des groupes avec survie faible | Aide à la décision clinique | dim_patients + fact_clinical_outcomes |

## Analyse statistique

Les analyses réalisées incluent :

- statistiques descriptives
- corrélations
- analyse comparative (breast vs lung)
- analyse de survie

#### Méthodes avancées (optionnel)

- Kaplan-Meier
- Log-rank test
- Modèle de Cox

## Dashboard BI

🔹 **Outil utilisé**

Power BI

### Page 1 — Overview

- vue globale de la population
- KPI principaux
- distribution cancer et risque

### Page 2 — Clinical Analysis

- impact du stade
- impact ECOG
- analyse âge / survie
- comparaison des groupes

### Page 3 — Decision Support

- biomarqueurs
- profils à risque
- analyse décisionnelle

## Valeur métier

Ce projet permet :

- d'identifier les patients à haut risque
- d'analyser les facteurs influençant la survie

- d’intégrer les biomarqueurs dans l’analyse
- d’aider à la prise de décision médicale

## Perspectives d’amélioration

- intégration de données multi-omics
- modèles de machine learning prédictifs
- scoring de risque patient
- automatisation du pipeline (ETL)
- intégration temps réel

## Conclusion

Ce projet illustre la capacité à :

- construire un pipeline data complet
- analyser des données médicales complexes
- produire des indicateurs décisionnels
- transformer la donnée en **outil d’aide à la décision clinique**